

目录

第 1 章 基于监督学习的智能协议与参数联合选择方法，简要版 1

第 2 章 基于监督学习的智能协议与参数联合选择方法 3

 2.1 统一接入框架设计 3

 2.2 构建面向协议优化的 AI 代理仿真模型 6

 2.3 基于 AI 代理仿真模型的快速预测与优化 7

 2.4 仿真结果 8

 2.5 本章小结 8

第 1 章 基于监督学习的智能协议与参数联合选择方法， 简要版

这里的一些数字符号与后面章节没有很对应，仅做参考。

1. 问题定义

设计一种协议框架的输入向量为

$$x_{in} \in \mathbb{R}^d,$$

其分量包含两类：一类是描述流量特征的参数 $\mathbf{x}$ ，另一类是描述基本网络规模等（如节点数量，接入概率 q 等）。令完整的输入向量为 $(\mathbf{x}, \mathbf{x}_{\text{common}})$ 。协议类型集合为 $\mathcal{P} = \{p_1, \dots, p_K\}$ 。对于每种协议 $p \in \mathcal{P}$ 还存在一组可调控制参数 $\theta \in \Theta_p$ （比如帧长度、码率、重复因子等，这些参数只有具体某协议才使用到）。仿真器（或精确评估器）记为算子

$$S : (x_{in}, p, \theta) \mapsto \mathbf{y},$$

其中 $\mathbf{y} \in \mathbb{R}^m$ 为性能指标向量，例如吞吐量 T 、平均时延 D 、公平性指标 F 等。

完整的优化流程包括三步：数据生成（仿真）、监督学习（拟合仿真模型）、AI 驱动优化/选择。

2. 数据生成（仿真设计）

- 在输入空间对 (x_{in}, p, θ) 进行采样，通过我们自己建构的框架，仿真输出得到性能指标 $\mathbf{y}$ ，最终得到训练集 $\mathcal{D} = \{(x_{in}^{(i)}, p^{(i)}, \theta^{(i)}), \mathbf{y}^{(i)}\}_{i=1}^N$ ，其中 $\mathbf{y}^{(i)} = S(x_{in}^{(i)}, p^{(i)}, \theta^{(i)})$ 。
- 采样策略应考虑覆盖性与效率：对连续参数可用拉丁超立方（Latin Hypercube）或 Sobol 序列；对离散协议类型按类别均衡采样；对突发/稀疏场景适当加密样本。
- 记录仿真噪声与随机性（例如多次重复实验以估计输出方差），为后续建模提供不确定性标注。

3. 构建 AI 模型

- 我们的核心目标是学习函数 f_ϕ (参数 ϕ)，使得

$$f_\phi(x_{in}, p, \theta) \approx S(x_{in}, p, \theta)。$$

- 模型选择建议：当输入维度与样本量较小且需要不确定性估计时，优先考虑高斯过程（GP）；若维度较高或数据较多，可采用深度神经网络（DNN）、树模型或集成（Ensemble）方法。
- 损失函数通常采用均方误差（MSE）或加权 MSE（对不同性能指标赋予不同重要性），并可在训练中同时拟合均值与方差（heteroscedastic 模型）以量化不确定性。

$$\mathcal{L}(\phi) = \frac{1}{N} \sum_{i=1}^N \|f_\phi(x_{in}^{(i)}, p^{(i)}, \theta^{(i)}) - \mathbf{y}^{(i)}\|_2^2。$$

一句话总结，就是 AI 帮助我们去除仿真这一个过程，从而快速获取具体一组输入参数下输出的性能指标向量。

4. 基于 AI 代理仿真模型的快速预测与优化

- 一旦得到 f_ϕ ，即可在毫秒级评估任意 (x_{in}, p, θ) 的性能估计 $\hat{\mathbf{y}} = f_\phi(x_{in}, p, \theta)$ ，替代昂贵的仿真。
- 给定单目标或多目标效用 $U(\mathbf{y})$ （须综合吞吐-延迟以应用效用），求协议与参数的最优组合：

$$(p^*, \theta^*) = \arg \max_{p \in \mathcal{P}, \theta \in \Theta_p} U(f_\phi(x_{in}, p, \theta))。$$

- **优化策略**：对连续参数空间可用网格/随机搜索或梯度方法（若代理可微）；对离散协议/组合空间，推荐用贝叶斯优化、演化算法或强化学习（将代理作为环境模型）进行高效搜索。
- 若代理模型自带不确定性（GP 或 ensemble），可将不确定性纳入决策（例如上置信界 UCB、概率改进 PI 或期望改进 EI），以平衡利用-探索。

一句话总结，就是完成 AI 方法去代替昂贵的仿真之后，问题就转化为一个优化问题。

第2章 基于监督学习的智能协议与参数联合选择方法

现代无线网络，特别是物联网（IoT）场景，面临着日益复杂多变的业务需求。不同业务在接入密度、数据包长度、延迟敏感度等方面存在显著差异，加之网络负载的动态变化，使得任何单一的随机接入协议（如 ALOHA 或 CSMA 类协议）都难以在所有条件下持续保持最优性能。依赖固定协议与静态参数配置的传统设计，无法同时兼顾吞吐量、时延与公平性等多维性能指标，在特定场景下往往表现出局限性。例如，

未完成：插入不同协议类型的定性性能分析表。

为了应对这一挑战，一个自然的思路是根据当前场景的实时特征，动态地切换至最合适的接入协议，并同步优化其关键控制参数。然而，要实现这一点，必须首先建立一个能够容纳并支持多类接入协议灵活切换的统一框架。在此基础上，核心问题便转化为：如何依据实时网络状态，智能地选择最适配的接入协议，并自适应地优化其参数？

针对此问题，本章提出一种面向复杂业务场景的、基于监督学习的智能协议与参数联合选择方法。该方法旨在将网络接入策略从传统的“人工预设”模式，跃迁至“环境驱动的智能决策”新模式，从而在吞吐量、时延、公平性等多维度性能之间实现更优的平衡。

2.1 统一接入框架设计

构建统一接入框架的核心目标，是将不同类型的随机接入协议视为若干可调度、可组合的“统计接入模式”（Statistical Access Modes）。通过对网络状态，特别是流量统计特征的精确刻画，来驱动协议类型与相关参数的智能选择。这种设计将接入机制的选择从协议的逻辑层面，提升到了统计建模层面，为后续引入人工智能方法奠定了坚实基础。

2.1.1 标准化输入特征向量

为了让模型能够统一处理不同协议和场景，我们首先定义一个标准化的输入特征向量 $\mathbf{X}_{in}$ 。该向量旨在全面地描述一个特定的接入场景，其输入特征可分为以下三大类：

- **业务流量特征 ($\mathbf{x}_{traffic}$)**：用于刻画具体流量场景的紧凑向量，例如数据包的平均到达率、突发程度和周期性等。其具体的量化方式将在下一小节详述。

- **通用网络参数 ($\mathbf{x}_{\text{common}}$):** 包含所有协议都通用的基本网络规模参数, 是描述网络环境的基础。例如:
 - N : 网络中的终端节点总数。
- **协议专属参数 ($\mathbf{x}_{\text{proto}}$):** 一个包含了各类协议专属可调参数的超集。对于某个特定的协议, 只有其中一部分参数是有效的。例如:
 - p : 协议类型, 其中 $p \in \mathcal{P} = \{p_1, \dots, p_K\}$ 。
 - q : 接入概率 (适用于 ALOHA 类协议)。
 - M : 连续传输长度 (适用于 CBA 协议)。
 - L : 副本数量 (适用于 IRSA、CRDSA 等协议)。
 - F : 帧长度 (适用于 CRDSA 等成帧协议)。

为保证输入向量具有统一的维度, 我们将通用参数与协议专属参数拼接成一个统一的参数向量 $\mathbf{x}_{\text{param}} = [\mathbf{x}_{\text{common}}, \mathbf{x}_{\text{proto}}]$ 。对于在特定协议下不适用的参数, 我们采用占位符填充, 并引入一个有效性掩码 (validity mask) $\mathbf{x}^{(\text{mask})}$ 来标示每个参数的有效性:

$$x_k^{(\text{mask})} = \begin{cases} 1, & \text{若第 } k \text{ 个参数在当前样本中有效} \\ 0, & \text{若该参数不适用} \end{cases} \quad (2-1)$$

最终, 完整的标准化输入向量可表示为 $\mathbf{X}_{\text{in}} = (\mathbf{x}_{\text{traffic}}, \mathbf{x}_{\text{param}}, \mathbf{x}^{(\text{mask})})$ 。通过这种方式, 框架能够利用统一的输入结构处理多样化的协议, 同时让后续的 AI 模型能够清晰地辨别哪些特征在当前场景下是相关的。

2.1.2 业务流量特征的量化表示

为在统一框架下对不同类型的物联网业务流量 (如均匀、突发、周期性) 进行统一描述, 本章设计了一个紧凑的三维流量特征向量 $\mathbf{x}_{\text{traffic}} = [\rho, \text{BI}, \Psi]$ 。相比直接使用原始参数 (如到达概率、突发窗口长度等), 该低维特征向量能够更好地对三类典型流量模型进行抽象, 显著降低后续智能算法的学习复杂度。

在构造该特征前, 设定观测窗口长度为 W , 记 $A(t)$ 为系统在时隙 t 的总到达包数。在窗口 $[t - W + 1, t]$ 内, 可估计其均值 $\bar{A}$ 与方差 Var 。基于此, 三维特征定义如下:

- 1) **归一化到达率 (Normalized Load, ρ):** 系统平均到达率的归一化表示, 定义为 $\rho = \min(\bar{A}/\lambda_{\text{max}}, 1)$, 其中 λ_{max} 为经验设定的最大到达率。特征 $\rho \in [0, 1]$ 反映了系统整体负载强度, 是区分轻载、适中载与拥塞情形的核心指标。
- 2) **突发度指标 (Burstiness Index, BI):** 为刻画流量在统计意义上的离散度 (即是否存在

突发), 采用基于离散指标 (Index of Dispersion, ID) 的突发度定义。其中 $ID = \text{Var}/\bar{A}$, 而 $BI = (ID - 1)/(ID + 1)$ 。BI 的取值区间为 $(-1, 1)$: 当 BI 接近 0 时, 流量接近泊松分布; BI 大于 0 表示流量具有强突发性; BI 小于 0 则表示流量具有周期性或更规则的结构。

- 3) **周期性强度 (Periodicity Score, Ψ)**: 为衡量到达过程的周期结构, 采用样本自相关函数 $R(\tau)$ 计算周期性得分: $\Psi = \max_{1 \leq \tau \leq \tau_{\max}} R(\tau)/R(0)$, 其中 $\tau_{\max}$ 为可能的最大周期长度。若流量具有强周期性, 则 Ψ 接近 1; 若无显著周期性, 则 Ψ 接近 0。

2.1.3 仿真器定义与性能评估

在标准化输入的基础上, 我们构建了一个统一的仿真评估流程。其核心是一个仿真器 S , 它接收完整的输入向量 $\mathbf{X}_{\text{in}}$, 构建出特定的网络场景并执行仿真, 最终输出一组衡量网络性能的关键指标向量 $\mathbf{y}$ 。此过程可抽象为算子:

$$S : \mathbf{X}_{\text{in}} \mapsto \mathbf{y} \quad (2-2)$$

我们关注的性能指标向量 $\mathbf{y}$ 主要由吞吐量 (Throughput, T)、平均时延 (Delay, D) 和公平性 (Fairness, F) 这三个关键维度构成:

$$\mathbf{y} = [T, D, F] \quad (2-3)$$

由于这些指标间常存在权衡关系 (trade-off), 直接比较多维向量 $\mathbf{y}$ 是困难的。为对不同配置下的综合性能进行统一量化与排序, 我们引入一个单变量效用函数 $U(\mathbf{y})$, 通过对各项指标进行线性加权, 将多目标评估问题转化为单目标优化问题:

$$U(\mathbf{y}) = w_T \cdot T - w_D \cdot D + w_F \cdot F \quad (2-4)$$

其中, w_T, w_D, w_F 为各项指标的非负权重, 反映了具体应用场景对不同性能的偏好。时延项为负, 因其是成本型指标。因此, 协议与参数的联合优化目标可形式化为:

$$(p^*, \mathbf{x}_{\text{proto}}^*) = \arg \max_{p \in \mathcal{P}, \mathbf{x}_{\text{proto}}} U(S(\mathbf{X}_{\text{in}})) \quad (2-5)$$

2.2 构建面向协议优化的 AI 代理仿真模型

2.2.1 构建动机

虽然仿真器 S 能够精确评估特定配置下的协议性能，但其过程往往极为耗时，动辄需要数小时乃至数天才能完成一次参数扫描。这种低效率严重制约了对大规模、多维度参数空间的探索，使得协议的快速设计与自适应调优变得不切实际。

为解决此瓶颈，本章的核心思想是构建一个高效的 AI 代理仿真模型（AI-driven Surrogate Model）。我们旨在训练一个机器学习模型 f_ϕ （以 ϕ 为参数），使其能够精准地学习并复现从输入特征 $\mathbf{X}_{in}$ 到性能指标 $\mathbf{y}$ 的复杂映射关系：

$$\hat{\mathbf{y}} = f_\phi(\mathbf{X}_{in}) \approx S(\mathbf{X}_{in}) \quad (2-6)$$

一旦训练完成，该代理模型便可在毫秒级别完成一次性能预测，相比传统仿真实现了数万倍乃至更高的加速，为实现协议参数的实时优化与在线自适应调整提供了核心技术支撑。

2.2.2 监督学习数据集构建

要训练代理模型 f_ϕ ，首先必须构建一个高质量的数据集 $\mathcal{D}$ 。该过程遵循标准的监督学习范式，具体流程如下：

- 1) **参数采样**：在合法的参数空间中对输入向量 $\mathbf{X}_{in}$ 进行广泛采样。为保证样本的多样性与覆盖性，可采用拉丁超立方采样（Latin Hypercube Sampling）等高级采样技术。
- 2) **执行仿真**：对每一个采样得到的参数组合 $\mathbf{X}_{in}^{(i)}$ ，调用耗时的仿真器 S 运行仿真，得到其精确的性能指标向量 $\mathbf{y}^{(i)} = S(\mathbf{X}_{in}^{(i)})$ 。
- 3) **构建数据集**：将所有输入-输出对进行组合，最终形成训练数据集 $\mathcal{D} = \{(\mathbf{X}_{in}^{(i)}, \mathbf{y}^{(i)})\}_{i=1}^N$ ，其中 N 为样本总数。

2.2.3 多任务神经网络模型与训练策略

考虑到输入特征的复杂性以及输出指标的多维性，我们采用多任务深度神经网络（Multi-Task DNN）作为代理模型的基本架构。其结构设计如下：

- **输入层**：接收统一的、拼接后的特征向量 $\mathbf{X}_{in}$ 。

- **共享隐藏层**：由多层全连接层（Fully Connected Layers）构成，用于从原始输入中学习并提取高阶的、共享的特征表示。
- **任务特定输出层**：在共享层的顶端，为每一个性能指标（ T, D, F ）分别设置一个或多个独立的全连接层，用于从共享特征中解码出各自的预测值。

这种架构能够利用不同预测任务之间的内在关联性，提升模型的学习效率和泛化能力。

模型的训练策略包括：

- 1) **数据预处理**：对输入数据进行归一化处理，并利用有效性掩码 $\mathbf{x}^{(\text{mask})}$ 对输入层或损失计算进行相应处理，以屏蔽无效参数的干扰。
- 2) **损失函数**：由于性能指标是连续值，我们采用均方误差（Mean Squared Error, MSE）作为回归任务的损失函数 $\mathcal{L}_{\text{MSE}}$ 。对于多任务模型，总损失为各任务损失的加权和。
- 3) **优化器**：采用 Adam 优化器，并结合学习率衰减与早停（Early Stopping）策略，以防止模型过拟合，并确保训练过程的稳定收敛。
- 4) **训练流程**：将数据集划分为训练集、验证集和测试集。在训练集上迭代优化模型参数 ϕ ，在验证集上监控性能并调整超参数（如网络层数、节点数等），最终在独立的测试集上评估模型的最终性能。

2.3 基于 AI 代理仿真模型的快速预测与优化

在 AI 代理模型 f_ϕ 训练完成后，原先耗时的协议优化问题便转化为一个可在毫秒级求解的数学优化问题。给定一个业务场景的流量特征 $\mathbf{x}_{\text{traffic}}$ ，目标是快速找到最优的协议类型 p^* 及其对应的专属参数 $\mathbf{x}_{\text{proto}}^*$ ：

$$(p^*, \mathbf{x}_{\text{proto}}^*) = \arg \max_{p \in \mathcal{P}, \mathbf{x}_{\text{proto}}} U(f_\phi(\mathbf{x}_{\text{traffic}}, p, \mathbf{x}_{\text{proto}}, \dots)) \quad (2-7)$$

由于代理模型 f_ϕ 的评估速度极快，我们可以采用高效的搜索算法来求解此优化问题。针对该问题的混合（离散与连续）参数空间特性，可以选择以下优化策略：

- **贝叶斯优化 (Bayesian Optimization)**：尤其适用于“黑盒”且评估成本较高的函数优化，即使在这里评估成本已大大降低，它依然能够高效地平衡探索（Exploration）与利用（Exploitation），以较少的迭代次数找到全局最优解。
- **演化算法 (Evolutionary Algorithms)**：如遗传算法（Genetic Algorithm），能够并行地在参数空间中进行全局搜索，对目标函数的形态要求较低，鲁棒性好。
- **强化学习 (Reinforcement Learning)**：可将协议和参数选择视为一个决策过程，将代理模型作为环境（Environment）的一部分，通过训练一个智能体（Agent）来学习最

优的决策策略。

通过这些先进的优化算法，系统能够在业务状态发生变化时，实现对接入策略的快速、自适应调整。

2.4 仿真结果

2.5 本章小结

本章提出了一种基于监督学习的智能协议与参数联合选择方法，旨在解决传统单一接入协议在复杂多变业务场景下的性能局限性。首先，我们设计了一个统一的接入框架，通过标准化的输入特征向量，对不同的业务流量、网络规模和协议参数进行统一建模。随后，为克服传统网络仿真的高时间成本，我们引入了 AI 代理模型的思想，利用多任务深度神经网络学习并复现了从输入特征到多维性能指标的复杂映射关系。最后，基于训练好的、能够进行毫秒级预测的代理模型，将原先难以处理的协议优化问题，转化为一个可由高效搜索算法求解的数学问题。

综上所述，本章通过“统一框架设计-代理模型构建-快速优化求解”三步，为实现随机接入机制的智能化和自适应化提供了完整的理论与实践基础。